

Estrategia de Optimización de Costos y Recursos

Ecosistema de Automatización IA Autónomo — Vector Consultores

Autor: Matías Medrano · Módulo 8, Proyecto Integrador · Volumen de referencia: 1.000 leads/mes

Precios verificados el 29 de agosto de 2026 contra las páginas oficiales de pricing de OpenAI y Anthropic. Las tarifas de API se revisan con frecuencia; toda proyección presupuestaria debe reconfirmarse antes de comprometer un presupuesto real.

1. La tesis de este documento

Hay una tentación previsible al construir una automatización con IA: elegir el modelo más potente disponible y usarlo para todo. Es cómodo, funciona, y es la forma más rápida de gastar cuatro veces lo necesario. La tesis contraria, que este sistema implementa, es que **la asignación de modelos es una decisión de arquitectura, no una preferencia**. Cada tarea del flujo tiene un perfil distinto de complejidad, volumen y urgencia, y ese perfil determina qué herramienta corresponde. Clasificar mil emails cortos y redactar una propuesta a partir de un pliego de cuarenta páginas son problemas diferentes; resolverlos con el mismo modelo significa pagar de más en uno de los dos casos. La regla que ordena todas las decisiones que siguen:

Usar el modelo más barato que resuelva la tarea con éxito.

Tiene dos filos. Un modelo caro en una tarea simple es presupuesto quemado sin beneficio. Un modelo débil en una tarea crítica es un ahorro que se paga con calidad, y termina costando más caro que la diferencia de tarifa.

2. Cuadro comparativo de modelos

Tarifas oficiales por millón de tokens, en dólares, al 29 de agosto de 2026.

Modelo / modo	Input	Output	Relación vs. mini	Decisión
GPT-4o-mini	0,15	0,60	1×	Adoptado — clasificación y extracción
GPT-4o	2,50	10,00	~17×	Descartado — sin ventaja en tareas de etiquetado
Claude Haiku 4.5	1,00	5,00	~7×	Evaluable — ver nota abajo
Claude Sonnet	3,00	15,00	20×	Adoptado — lectura densa y redacción
Claude Sonnet · escritura de caché	3,75	—	—	Adoptado — primera carga del prefijo
Claude Sonnet · lectura de caché	0,30	—	—	Adoptado — 90% menos
Claude Sonnet · Message Batches	1,50	7,50	—	Adoptado — 50% menos
Claude Opus	5,00	25,00	33×	Descartado — sobredimensionado para el caso

Nota sobre Haiku 4.5. Es el candidato natural para clasificación de alto volumen dentro de la familia Claude, y se evaluó como alternativa a GPT-4o-mini. Se descartó por precio: a 1,00/5,00 resulta unas siete veces más caro que mini en una tarea donde ambos rinden igual. Usar dos proveedores distintos agrega algo de complejidad operativa, pero la diferencia de costo la justifica.

Aviso de vigencia. Claude Sonnet 5 tiene una tarifa introductoria de 2,00/10,00 vigente hasta el 31 de agosto de 2026; desde el 1 de septiembre pasa a 3,00/15,00. **Todos los cálculos de este documento usan la tarifa estándar de 3,00/15,00**, para no construir un presupuesto que caduque en dos días. La consecuencia práctica es que los números presentados son el escenario conservador: el costo real durante agosto es menor.

3. Matriz de decisión estratégica

Cada tarea del flujo se evaluó contra cuatro criterios antes de asignarle un modelo.

Tarea	Complejidad	Volumen	¿Urgente?	Riesgo si falla	
Clasificar segmento, urgencia e intención	Baja	Alto (1.000/mes)	Sí	Bajo — corregible	GPT-4o-mini
Extraer datos del cuerpo del mensaje	Baja	Alto	Sí	Bajo	GPT-4o-mini
Redactar respuesta estándar breve	Media-baja	Medio (800/mes)	Sí	Medio — lo revisa un humano	GPT-4o-mini
Leer pliego adjunto y redactar propuesta	Alta	Bajo (200/mes)	Sí	Alto — compromiso comercial	Claude Sonnet
Informe mensual de insights	Media	Alto (1.000/mes)	No	Bajo	Claude vía Batches
Contexto estático repetido (catálogo, marca)	—	Recurrente	—	—	Prompt Caching
Rutear por score, deduplicar, formatear	Nula	Alto	Sí	Bajo	Sin IA — lógica nativa

3.1 Justificación de las cuatro decisiones que importan

Tareas mecánicas → GPT-4o-mini. Clasificar y extraer son problemas de etiquetado con salida corta y estructurada. No requieren razonamiento profundo ni contexto extenso: requieren seguir un esquema. Un modelo premium acá no clasifica mejor, solo cuesta veinte veces más. Con salida restringida por JSON Schema y temperature: 0, la variabilidad que podría justificar un modelo superior queda acotada por diseño.

Lectura densa → Claude Sonnet. Cuando entra un lead VIP con un pliego adjunto, la tarea cambia de naturaleza: hay que sostener el hilo a lo largo de un documento largo, cruzarlo con el historial del cliente y producir un texto que la empresa va a firmar. Acá el modelo económico falla de la peor forma — no arroja error, produce algo plausible pero incorrecto. Son 200 casos al mes sobre 1.000: el 20% del volumen concentra el 100% del riesgo comercial, y es exactamente donde conviene gastar.

Proceso masivo no urgente → Message Batches. El informe mensual analiza los mil leads del período cerrado. Nadie lo espera en tiempo real; se lee el primer día del mes siguiente. Pagar tarifa de tiempo real por un proceso que puede esperar veinticuatro horas es pagar por una velocidad que no se usa. La Batch API entrega **50% de descuento** a cambio de esa espera.

Contexto repetido → Prompt Caching. El prompt de análisis incluye el catálogo de servicios y el manual de marca: unos 6.000 tokens idénticos en cada una de las 200 llamadas mensuales. Sin caché se pagan 200 veces a tarifa plena. Con caché se paga una escritura y 199 lecturas al **10% del precio**.

Lo que no lleva IA. Comparar un número contra un umbral, verificar si un ID ya existe, dar formato a un texto: todo eso lo resuelve un nodo condicional, gratis, instantáneo y sin posibilidad de alucinar. Delegar lógica determinística a un LLM es el error de diseño más caro y más común.

4. Demostración cuantitativa del ahorro

4.1 Supuestos

Parámetro	Valor
Leads mensuales	1.000
Proporción VIP (requieren análisis denso)	20% → 200 leads
Clasificación: tokens por lead	800 input / 200 output
Análisis VIP: prefijo estático	6.000 input
Análisis VIP: parte variable	2.000 input / 900 output
Insight mensual: tokens por lead	600 input / 250 output

4.2 Escenario A — sin optimizar

Todo el procesamiento con Claude Sonnet a tarifa estándar, sin caché ni batches. Es la línea de base contra la que se mide el ahorro.


Concepto	Cálculo	Costo
Clasificación × 1.000	(0,80 M × 3,00) + (0,20 M × 15,00)	2,40 + 3,00 = 5,40
Análisis VIP × 200	(1,60 M × 3,00) + (0,18 M × 15,00)	4,80 + 2,70 = 7,50
Insights × 1.000	(0,60 M × 3,00) + (0,25 M × 15,00)	1,80 + 3,75 = 5,55
		18,45 USD/mes

4.3 Escenario B — optimizado

Concepto	Cálculo	Costo
Clasificación × 1.000 con GPT-4o-mini	(0,80 M × 0,15) + (0,20 M × 0,60)	0,12 + 0,12 = 0,24
Prefijo cacheado: 1 escritura + 199 lecturas	(0,006 M × 3,75) + (1,194 M × 0,30)	0,02 + 0,36 = 0,38
Análisis VIP: parte variable + output	(0,40 M × 3,00) + (0,18 M × 15,00)	1,20 + 2,70 = 3,90
Insights × 1.000 vía Batches (~50%)	(0,60 M × 1,50) + (0,25 M × 7,50)	0,90 + 1,88 = 2,78
		7,30 USD/mes

4.4 Resultado

Escenario A (sin optimizar)		18,45 USD/mes
Escenario B (optimizado)		7,30 USD/mes
Ahorro absoluto		11,15 USD/mes
Ahorro relativo		60,4 %
Proyección anual ahorrada		133,80 USD/año



4.5 Contribución de cada palanca

Palanca	Ahorro que aporta	Sobre qué actúa
Modelo económico en tareas mecánicas	5,16 USD/mes	95,6% del costo de clasificación
Prompt Caching del prefijo estático	4,42 USD/mes	92,1% del costo del contexto repetido
Message Batches en el proceso masivo	2,77 USD/mes	Exactamente el 50% del informe mensual
Total	11,15 USD/mes	60,4% del gasto total

El objetivo del 50% se supera, y vale precisar de dónde sale cada punto. **Batches aporta exactamente su 50% contractual** sobre el proceso al que aplica. **Caching aporta el 90%** sobre el contexto repetido. Y la asignación por tarea aporta el resto, que resulta ser la palanca individual más grande — porque actúa sobre el volumen más alto del sistema.

5. Advertencias técnicas

Un análisis de costos que solo muestra el ahorro es marketing. Estas son las condiciones bajo las cuales cada palanca deja de convenir.

- El caché tiene un costo de entrada.** La primera escritura cuesta 25% más que el input normal. En un flujo que se ejecuta una sola vez, el caché **encarece**. Solo conviene con volumen recurrente sobre el mismo prefijo — que es el caso acá, con 200 llamadas mensuales, pero no lo sería en un proceso esporádico.
- El caché expira.** El TTL es de unos 5 minutos, renovable con cada lectura. Si los leads VIP llegaran muy espaciados, cada llamada pagaría escritura en lugar de lectura y el ahorro se evaporaría. Con 200 mensuales el flujo es suficientemente denso, pero es una hipótesis del modelo de costos, no una garantía.
- Cambiar una palabra del prefijo invalida el caché.** El bloque cacheado debe ser idéntico byte a byte. Por eso el prefijo vive en un campo aparte de `PRM_Prompts` y se versiona: cualquier edición es visible y su impacto en el costo, previsible.

Batches no sirve para nada sincrónico. Hacer esperar veinticuatro horas a un cliente por una respuesta de WhatsApp para ahorrar centavos es cambiar dinero por reputación al peor tipo de cambio. Batches se usa exclusivamente en el sub-flujo mensual, y esa restricción está en la arquitectura, no en la buena voluntad de quien opere el sistema.

Los precios cambian. Entre el momento de escribir este documento y su lectura pueden haber cambiado las tarifas, como ilustra el propio caso de la tarifa introductoria de Sonnet 5. Por eso los nombres de modelo viven en `CFG_Config` y no dentro de los nodos: migrar de proveedor es editar dos filas de una tabla, no reconstruir el flujo.

6. Costo total de propiedad

El costo de IA es solo una parte del gasto. Estimación de plataforma a volumen de 1.000 leads/mes:

Componente	Modalidad	Costo mensual estimado
Procesamiento IA	Ver cálculo anterior	7,30
n8n	Self-hosted en VPS pequeño	~8 - 12
Airtable	Plan gratuito (bajo el límite de registros)	0
Slack	Plan gratuito	0
Gmail	Cuenta de trabajo existente	0
WhatsApp Business API	Por conversación iniciada, uso bajo	~5 - 15
Total estimado		≈ 20 - 35 USD/mes

Los costos de plataforma son estimaciones de lista y dependen del proveedor de VPS, la región y el volumen efectivo de conversaciones de WhatsApp. Deben confirmarse antes de comprometer un presupuesto.

Elegir n8n self-hosted sobre la versión Cloud es la segunda decisión de costo más relevante después de la asignación de modelos: a este volumen, un VPS chico cuesta una fracción de la suscripción y no impone límite de ejecuciones.

6.1 Retorno

El sistema procesa 1.000 leads mensuales. Leer, clasificar, buscar el historial y redactar una respuesta lleva a una persona unos **12 minutos por lead**, lo que equivale a **200 horas mensuales** — más de una persona a tiempo completo.

El sistema no elimina esas 200 horas: preserva deliberadamente el punto de aprobación humana. Pero convierte la tarea de *redactar desde cero* en *revisar y aprobar*, que toma alrededor de 2 minutos. El tiempo humano baja a unas 33 horas mensuales.

Concepto	Antes	Después
Horas humanas mensuales	200	~33
Horas liberadas	—	~167
Costo de plataforma	0	~20 - 35 USD

Aun valuando la hora de forma conservadora, el costo del ecosistema equivale a una fracción mínima del tiempo que libera. La relación no es marginal, es de dos órdenes de magnitud — y esa asimetría, no la optimización de tokens, es el verdadero argumento económico del proyecto. La optimización de costos importa porque hace que el gasto sea **irrelevante frente al beneficio**, y por lo tanto que el proyecto no dependa de justificar su presupuesto.

7. Síntesis

Decisión	Fundamento	Impacto
GPT-4o-mini para tareas mecánicas	La tarea no requiere razonamiento; el modelo caro no rinde mejor	~95,6% en clasificación
Claude Sonnet para lectura densa	El 20% del volumen concentra el 100% del riesgo comercial	Calidad donde importa
Prompt Caching del contexto estático	6.000 tokens idénticos en 200 llamadas mensuales	~90% en contexto repetido
Message Batches para el informe mensual	Nadie espera el reporte en tiempo real	~50% contractual
Lógica nativa para lo determinístico	Un <code>IF</code> es gratis y no alucina	Costo cero
Modelos parametrizados en <code>CFG_Config</code>	Los precios cambian; la arquitectura no debería	Migración de dos celdas

Resultado: 60,4% de ahorro mensual sobre la línea de base, superando el objetivo del 50%.